Análise de Dados

Apresentação da disciplina e desafio do semestre

Aléssio Tony Cavalcanti de Almeida

Centro de Ciências Sociais Aplicadas
Universidade Federal da Paraíba
alessio@lema.ufpb.br

CIÊNCIA DE DADOS PARA NEGÓCIOS

João Pessoa, 2026

Sobre o professor

Prof. Dr. Aléssio Tony Cavalcanti de Almeida

Áreas de interesse: monitoramento e avaliação de projetos, engenharia de dados, modelagem aplicada, indicadores de políticas públicas e sistemas de inteligência de dados.

E-mails institucionais
alessio@lema.ufpb.br
alessio.almeida@academico.ufpb.br

CV Lattes

Projetos em andamento

1. Sistemas de informação a partir de Notas Fiscais Eletrônicas – TCE-PB.
2. Territorialização dos ODS no Estado da Paraíba usando IA – FAPESQ.
3. Sistema de Monitoramento Acadêmico usando Inteligência Artificial – FAPESQ.
4. Sistema de Inteligência de Dados de Ciência e Tecnologia do Estado da Paraíba – SECTIES-PB/FAPESQ.
5. Plataforma ODS Racial: monitoramento e avaliação – MIR.
6. Gap Tributário e Plataforma de Integração de Dados – SEFAZ-PB.
7. Observatório dos Egressos da Rede Federal de Educação Profissional, Científica e Tecnológica – SETEC/MEC.
8. Sistemas de inteligência de dados para gestão da UFPB – CODEINFO.
9. Minerador de Preços – Projeto ALTA: estimativas de custos com alimentação, tabaco e bebidas – CNPq.
10. Vacinação na Atenção Primária à Saúde e apoio para recuperação da cobertura vacinal – MS/UnB.
11. Estimação da despesa com pessoal da Atenção Primária à Saúde (APS) nos municípios brasileiros – OPAS/OMS/MS.
12. Plataforma Digital de informações estratégicas sobre os territórios rurais da Paraíba – MDA.

Por que Análise de Dados em Ciência de Dados para Negócios?

Ideia central da disciplina

Análise de dados é a capacidade de transformar um problema real em uma sequência técnica e comunicável: pergunta, dados, tratamento, evidências, visualizações, interpretação e recomendação.

- **Decisão**: apoiar escolhas públicas ou privadas com base em evidências.
- **Processo**: estruturar projetos analíticos de forma reprodutível e auditável.
- **Produto**: entregar algo útil, como relatório, notebook, painel, diagnóstico ou protótipo.
- **Comunicação**: traduzir dados em argumentos claros para gestores, equipes técnicas e sociedade.

Plano da disciplina

Informações gerais

Turma, comunicação e materiais

- Turma virtual no SIGAA: **PSAE00263 – Análise de Dados – T01**.
- Ambiente complementar: repositório Git da disciplina <https://github.com/ufpbcdn/analise-dados>.
- Materiais: slides, notebooks, bases de dados, roteiros práticos e entregáveis do projeto.

<https://sigaa.ufpb.br>

Ementa operacional da disciplina

Da ementa formal para a prática do semestre

- Contexto, metodologias e processos de análise de dados.
- Introdução ao Python para análise de dados, com foco em `pandas`, `numpy` e notebooks.
- Entrada de dados: `csv`, `txt`, `xlsx`, `xml`, `html`, `json`, APIs e bancos de dados.
- Preparação e manipulação de dados estruturados: filtros, seleção, atribuição, agregação, ordenamento, concatenação e combinação.
- Organização de dados, strings, datas, qualidade da base e construção de base analítica.
- Estatística descritiva, tabelas de frequência, visualização, interpretação e comunicação de resultados.

Objetivo geral

Objetivo da disciplina

Capacitar os estudantes a desenvolverem um produto analítico aplicado a um problema real, integrando definição do problema, obtenção de dados, preparação da base, análise exploratória, visualização, interpretação e comunicação de recomendações baseadas em evidências.

Resultado esperado ao final do semestre

Cada equipe deverá entregar uma solução analítica funcional, documentada e comunicável, construída em etapas cumulativas ao longo da disciplina.

Competências desenvolvidas

Competências técnicas

- Estruturar problemas analíticos.
- Ler dados de múltiplas fontes.
- Manipular bases com Python e pandas.
- Construir indicadores, tabelas e visualizações.
- Documentar códigos, bases e decisões metodológicas.

Competências aplicadas

- Comunicar evidências para públicos não técnicos.
- Trabalhar em equipe com versionamento.
- Avaliar qualidade, limites e riscos dos dados.
- Transformar análise em recomendação prática.
- Produzir um artefato útil para decisão.

Princípio pedagógico da disciplina

Não haverá prova tradicional

A avaliação será baseada no desenvolvimento de atividades individuais e um **produto final aplicado** com entregas progressivas.

- O foco não é memorizar comandos, mas resolver problemas com dados.
- Cada etapa gera um avanço concreto do produto final.
- O produto será desenvolvido com dados reais, públicos ou privados, respeitando disponibilidade, qualidade, ética e viabilidade técnica.
- A nota final refletirá processo, rigor, execução técnica, utilidade da solução e comunicação dos resultados.

Desafio do semestre

Desafio do semestre

Definição

O **desafio do semestre** será um problema real, público ou privado, que possa ser investigado com dados e convertido em um produto analítico com potencial de apoiar decisão.

Exemplos de desafios possíveis

- Monitorar desigualdades educacionais entre municípios, escolas ou grupos sociais.
- Diagnosticar padrões de evasão, desempenho ou permanência estudantil.
- Analisar comportamento de consumo, vendas, preços ou atendimento ao cliente.
- Mapear infraestrutura, cobertura de serviços ou indicadores territoriais.
- Criar painel de acompanhamento de metas, programas ou políticas públicas.

Critérios para escolha do desafio

Critério	**Pergunta orientadora**
Relevância	O problema importa para algum público, organização, território, setor ou política?
Viabilidade	Existem dados acessíveis, em prazo e formato compatíveis com a disciplina?
Clareza analítica	É possível formular perguntas, indicadores e recortes objetivos?
Potencial de decisão	A análise pode gerar recomendação, diagnóstico, priorização ou monitoramento?
Escopo	O desafio é simples o suficiente para caber em 60h e robusto o suficiente para gerar aprendizagem?
Ética e governança	O uso dos dados respeita privacidade, anonimização, segurança e uso responsável?

Produto final esperado

Produto analítico mínimo

Ao final da disciplina, cada equipe deverá entregar:

1. **Repositório organizado**: código, dados permitidos, documentação e instruções de reprodução.
2. **Base analítica tratada**: dados limpos, integrados, validados e documentados.
3. **Relatório técnico**: contexto do problema, métodos, dados utilizados, análises dos resultados, limitações e conclusões.
4. **Visualizações**: gráficos, tabelas e mapas interativos que comuniquem os principais achados.
5. **Síntese executiva**: problema, evidências, implicações, limitações e recomendações.

Uso responsável de Inteligência Artificial

Uso permitido

- Apoio para entender erros, revisar código e sugerir alternativas.
- Geração de exemplos, explicações e documentação inicial.
- Revisão textual e melhoria da clareza da comunicação.

Responsabilidade da equipe

- Todo código entregue deve ser compreendido e defendido pela equipe.
- Toda análise deve ser validada com os dados utilizados.
- O uso de IA deve ser declarado quando tiver impacto relevante no produto.
- Não é permitido submeter dados sensíveis, sigilosos ou identificados a ferramentas externas sem autorização.

Arquitetura mínima do projeto

Estrutura recomendada do repositório

```
projeto-analise-dados/
|-- README.md
|-- data/
|   |-- raw/          # dados brutos, quando permitido
|   |-- processed/    # dados tratados
|-- notebooks/
|-- src/              # funções auxiliares, quando necessário
|-- outputs/
|   |-- figures/
|   |-- tables/
|-- reports/
|-- requirements.txt ou environment.yml
```

Conteúdo e módulos

Conteúdo programático revisado

1. **Fundamentos**: análise de dados, ciência de dados, processo analítico, perguntas de negócio, indicadores e tomada de decisão.
2. **Python para análise de dados**: ambiente, notebooks, scripts, tipos básicos, estruturas de dados, pandas e numpy.
3. **Entrada de dados**: CSV, TXT, XLSX, HTML, JSON, XML, APIs, web scraping básico e bancos SQL.
4. **Preparação e qualidade**: unidade de análise, granularidade, chaves, tipos, ausentes, duplicidades, inconsistências e outliers.
5. **Manipulação de dados**: filtros, seleção, atribuição, agregação, ordenamento, concatenação, joins, strings e datetime.
6. **Análise exploratória**: estatísticas descritivas, tabelas de frequência, cruzamentos, indicadores e interpretação.
7. **Visualização e comunicação**: gráficos, dashboards, storytelling com dados e recomendações executivas.

Módulos da disciplina

1. Problema, dados e processo analítico.
2. Python, pandas e ambiente reprodutível.
3. Aquisição, preparação e integração de dados.
4. Estatística descritiva, indicadores e análise exploratória.
5. Visualização, comunicação e produto final.

Módulo I: problema, dados e processo analítico

Conteúdos

- O que é análise de dados e sua relação com ciência de dados.
- Problemas de negócio, problemas públicos e perguntas analíticas.
- Processo analítico: problema, dados, evidência, comunicação e decisão.
- Unidade de análise, instância, atributo, variável, chave e granularidade.
- Planejamento do desafio do semestre.

Entregável associado

Pré-projeto do desafio: problema, público-alvo, perguntas, fontes potenciais e produto esperado.

Módulo II: Python, pandas e ambiente reprodutível

Conteúdos

- Ambiente de trabalho: Python, VS Code ou Jupyter, Git, GitHub e Markdown.
- Noções essenciais de Python para análise de dados.
- DataFrames, Series, tipos de dados e operações básicas.
- Organização de repositório e documentação mínima.
- Reprodutibilidade: dependências, caminhos relativos e README.

Ferramentas centrais

Python
Pandas
NumPy
Git/GitHub
Markdown

Módulo III: aquisição, preparação e integração de dados

Conteúdos

- Leitura de arquivos: CSV, TXT, XLSX, JSON, XML e HTML.
- Coleta via APIs e consultas SQL básicas.
- Qualidade dos dados: ausentes, duplicidades, inconsistências, outliers e validações.
- Transformação: tipos, recodificação, criação de variáveis e padronização.
- Combinação de bases: concatenação, joins e validação de chaves.
- Operações com strings e datas em DataFrames.

Entregável associado

Pipeline inicial de dados: leitura, tratamento, dicionário de variáveis e primeira base analítica.

Módulo IV: estatística descritiva, indicadores e EDA

Conteúdos

- Estatísticas descritivas para variáveis numéricas e categóricas.
- Tabelas de frequência, proporções e cruzamentos.
- Construção de indicadores e medidas agregadas.
- Análise por grupos, tempo e território.
- Identificação de padrões, anomalias, tendências e limitações.

Entregável associado

Relatório exploratório: evidências iniciais, tabelas, gráficos, principais achados e problemas remanescentes.

Módulo V: visualização, comunicação e produto final

Conteúdos

- Princípios de visualização e design de informação.
- Gráficos univariados, bivariados e multivariados.
- Séries temporais, mapas, rankings e comparações.
- Storytelling com dados e comunicação executiva.
- Apresentação final do produto analítico.

Ferramentas possíveis

Matplotlib
Seaborn
Plotly
Dash/Streamlit
Markdown/Quarto

Metodologia e avaliação

Metodologia de ensino

Estratégia didática

- Aulas expositivas curtas para introdução dos conceitos essenciais.
- Demonstrações computacionais com notebooks e scripts em Python.
- Laboratórios práticos orientados por problemas.
- Desenvolvimento progressivo do desafio do semestre em equipes.
- Rodadas de orientação, revisão por pares e apresentação parcial dos resultados.

Papel dos exercícios

Os exercícios práticos terão função formativa: consolidar competências técnicas necessárias para avançar no produto final.

Avaliação: produto final em três etapas

Composição da média parcial

$$MP = 0,30AI + 0{,}10P_1 + 0{,}20P_2 + 0{,}40P_3$$

Etapa	Peso	Foco da entrega
AI	30%	Engajamento em atividades em sala de aula e realização de atividades individuais.
P_1	10%	Projeto 1: Problema, fontes de dados, perguntas analíticas, desenho do produto e plano de execução.
P_2	20%	Projeto 2: Aquisição, tratamento, integração, documentação dos dados e análise exploratória inicial.
P_3	40%	Projeto Final: análise consolidada, visualizações, comunicação executiva, recomendações e reprodutibilidade.

Atividades Individuais

Como será composta a nota AI?

1. Atividades práticas individuais em notebooks ou scripts.
2. Exercícios curtos de leitura, limpeza, manipulação e visualização de dados.
3. Entregas registradas no SIGAA.

Etapa P1: desenho do desafio e plano analítico

Entrega 1 – Problema e desenho da solução

- Formulação do problema real e justificativa de relevância.
- Definição do público-alvo ou tomador de decisão.
- Perguntas analíticas e hipóteses ou expectativas iniciais.
- Identificação das fontes de dados e avaliação preliminar de viabilidade.
- Definição do produto final pretendido: relatório, painel, notebook executivo, mapa, diagnóstico ou protótipo.

Entregáveis mínimos

Documento curto ou README inicial + apresentação relâmpago + estrutura inicial do repositório.

Etapa P2: base analítica e análise exploratória

Entrega 2 – Dados, preparação e primeiras evidências

- Scripts/notebooks de leitura dos dados.
- Tratamento de ausentes, duplicidades, tipos, categorias, datas e inconsistências.
- Integração de bases, quando aplicável, com validação de chaves e granularidade.
- Dicionário de variáveis e descrição da base analítica.
- Estatísticas descritivas, tabelas de frequência e primeiras visualizações.
- Registro de limitações, problemas de qualidade e decisões metodológicas.

Entregáveis mínimos

Notebook técnico + base tratada permitida + dicionário de dados + relatório exploratório inicial.

Etapa P3: produto analítico final

Entrega 3 – Solução comunicável para decisão

- Produto final funcional e documentado.
- Visualizações adequadas ao problema e ao público-alvo.
- Síntese dos principais achados e implicações práticas.
- Recomendações baseadas nas evidências produzidas.
- Discussão das limitações, riscos de interpretação e próximos passos.
- Apresentação final com defesa técnica e executiva da solução.

Entregáveis mínimos

Repositório final + relatório/notebook executivo + visualizações ou painel + apresentação oral.

Rubrica geral de avaliação

Dimensão	Peso	Critérios observados
Problema e utilidade	15%	Clareza do problema, relevância, público-alvo, potencial de decisão e adequação do escopo.
Dados e reprodutibilidade	20%	Fontes, leitura, organização do repositório, documentação, tratamento, rastreabilidade e execução do código.
Preparação e qualidade	20%	Validação, limpeza, integração, granularidade, chaves, tipos, ausentes, duplicidades e coerência da base final.
Análise e indicadores	20%	Estatísticas, cruzamentos, indicadores, interpretação, consistência dos achados e tratamento de limitações.
Visualização e comunicação	15%	Clareza visual, adequação dos gráficos, narrativa, síntese executiva e comunicação para decisão.
Apresentação e colaboração	10%	Defesa oral, domínio técnico, participação da equipe, uso de Git e resposta a questionamentos.

Critérios de aprovação e frequência

Média parcial

$$MP = 0,30AI + 0{,}10P_1 + 0{,}20P_2 + 0{,}40P_3$$

- Se $MP \geq 7$: aprovado por média.
- Se $MP < 4$: reprovado.
- Se $4 \leq MP < 7$: avaliação final, conforme normas acadêmicas.

Frequência

O estudante poderá faltar, sem justificativa, até 25% da carga horária da disciplina. Acima desse limite, estará reprovado por faltas, conforme regra institucional.

Observação

Como a avaliação é cumulativa, atrasos nas entregas comprometem o desenvolvimento do produto final.

A avaliação final consistirá em uma entrega individual de recuperação.

Cronograma sugerido por ciclo

Semanas	Foco	Conteúdos principais	Marco do projeto
1–2	Problema e processo	Análise de dados, ciência de dados, perguntas analíticas, unidade de análise e desafio do semestre	Formação das equipes
3–4	Python e ambiente	Python, notebooks, pandas, Git, Markdown e organização do repositório	Pré-projeto
5–6	Entrada de dados	CSV, XLSX, JSON, XML, HTML, API, SQL e web scraping básico	P_1
7–9	Preparação	Qualidade, tipos, ausentes, duplicidades, strings, datas, concatenação e joins	Base preliminar
10–11	EDA	Estatísticas descritivas, frequências, indicadores, agrupamentos e cruzamentos	P_2
12–14	Visualização	Gráficos, mapas, dashboards, narrativa e comunicação executiva	Produto em teste
15	Apresentações finais	Defesa técnica e executiva do produto analítico	P_3

Ferramentas

Ferramentas recomendadas

Obrigatórias ou centrais

- Python
- pandas e numpy
- Jupyter Notebook, JupyterLab ou VS Code
- Git e GitHub
- Markdown

Complementares

- matplotlib, seaborn e plotly
- SQLite ou outro banco relacional
- BeautifulSoup e requests
- Streamlit, Dash ou Power BI para painéis
- TypeScript ou JavaScript para protótipos web, quando aplicável
- LaTeX, Quarto ou Overleaf para relatórios mais formais

Enquete inicial I

Qual é o **sistema operacional** principal do seu computador?

Acesse **www.menti.com**

Enquete inicial II

Acesse **www.menti.com**

Seu nível de conhecimento em...

- Python
- pandas
- Git/GitHub
- Markdown
- SQL
- Visualização de dados

Enquete inicial III

Acesse **www.menti.com**

Qual tipo de problema você gostaria de resolver com dados?

- Educação
- Saúde
- Assistência social
- Segurança
- Mobilidade
- Finanças
- Economia
- Sustentabilidade
- Outro problema real

Análise de dados e Ciência de Dados

Análise de dados x Ciência de dados

? Quais são as diferenças entre **Análise de Dados** e **Ciência de Dados**, caso existam?

Análise de dados x Ciência de dados

Cientista

Detetive

Análise de Dados

Concentra-se em transformar dados em evidências para responder perguntas específicas, compreender padrões, produzir diagnósticos e apoiar decisões.

Exemplos

- Analisar dados de vendas para identificar produtos mais vendidos e sazonalidades.
- Avaliar campanhas de marketing para otimizar investimentos.
- Monitorar indicadores educacionais, acadêmicos, territoriais ou administrativos.
- Diagnosticar gargalos operacionais e propor priorização de ações.

Ciência de Dados

Vai além da análise descritiva e exploratória, incorporando modelagem estatística, aprendizado de máquina, automação, predição, otimização e sistemas inteligentes.

Exemplos

- Desenvolver modelo para prever risco de evasão, inadimplência ou abandono de clientes.
- Criar sistema de recomendação de produtos, serviços ou intervenções.
- Analisar textos, imagens ou dados não estruturados.
- Construir sistemas de apoio à decisão com atualização contínua.

Análise de Dados e Ciência de Dados: um contínuo

Ideia central

Análise de Dados e Ciência de Dados compartilham fundamentos, ferramentas e objetivos. A diferença principal está no grau de automação, modelagem, integração computacional e incorporação da solução em processos decisórios.

- Análise de Dados: responder perguntas, produzir diagnósticos e comunicar evidências.
- Ciência de Dados: além disso, construir modelos, sistemas, predições, automações e produtos de dados.
- Em ambos os casos, o ponto de partida deve ser um problema bem formulado.
- Sem boa análise de dados, não há ciência de dados robusta.

Comparação sintética

Característica	Análise de Dados	Ciência de Dados
Objetivo	Responder perguntas, diagnosticar problemas e comunicar evidências.	Descobrir padrões, prever eventos, automatizar decisões e criar soluções inteligentes.
Foco	Dados estruturados, indicadores, exploração, visualização e interpretação.	Dados estruturados e não estruturados, modelagem, predição e sistemas.
Métodos	Estatística descritiva, análise exploratória, visualização e comunicação.	Estatística, machine learning, IA, otimização e engenharia de dados.
Entregáveis	Relatórios, painéis, diagnósticos, análises e recomendações.	Modelos preditivos, APIs, produtos de dados, sistemas inteligentes e experimentos.
Exemplos	Monitoramento de indicadores, análise de vendas, avaliação de campanhas.	Previsão de evasão, recomendação, detecção de anomalias, NLP.

Princípio de organização dos dados

Dados organizados para análise

Uma base bem estruturada facilita manipulação, visualização, modelagem e comunicação.

- Cada variável deve formar uma coluna.
- Cada observação deve formar uma linha.
- Cada tipo de unidade observacional deve formar uma tabela.
- Bases mal estruturadas aumentam o custo de limpeza e o risco de erro analítico.

O que é uma base analítica?

Definição prática

Uma base analítica é uma tabela ou conjunto de tabelas estruturadas para responder às perguntas do projeto, com unidade de análise clara, variáveis documentadas, chaves consistentes e qualidade mínima validada.

- Unidade de análise: município, escola, aluno, produto, venda, atendimento, evento etc.
- Granularidade: nível de detalhe de cada linha da base.
- Chaves: campos usados para identificar registros e integrar tabelas.
- Variáveis: atributos originais ou construídos para análise.
- Validação: checagem de duplicidades, ausentes, tipos, categorias e coerência.

Referências

Referências principais

Análise de dados com Python

- McKinney, W. *Python for Data Analysis*. 3. ed. O'Reilly, 2022.
- VanderPlas, J. *Python Data Science Handbook*. 2. ed. O'Reilly, 2023.
- Molin, S. *Hands-On Data Analysis with Pandas*. 2. ed. Packt, 2021.

Estatística, dados e visualização

- Bussab, W. O.; Morettin, P. A. *Estatística Básica*.
- Wickham, H. Tidy Data. *Journal of Statistical Software*, 2014.
- Wilke, C. O. *Fundamentals of Data Visualization*. O'Reilly, 2019.

Referências complementares

Processo analítico, negócios e comunicação

- Chapman et al. *CRISP-DM 1.0: Step-by-step Data Mining Guide*. SPSS, 2000.
- Microsoft. *Team Data Science Process*.
- Provost, F.; Fawcett, T. *Data Science for Business*. O'Reilly, 2013.
- Kelleher, J. D.; Tierney, B. *Data Science*. MIT Press, 2018.
- Knaflic, C. N. *Storytelling with Data*. Wiley, 2015.
- Healy, K. *Data Visualization: A Practical Introduction*. Princeton University Press, 2019.

Bibliografia: organização por função didática

A bibliografia da disciplina combina referências operacionais, metodológicas, estatísticas e comunicacionais, cada uma associada a uma etapa do desenvolvimento do produto analítico.

Base operacional de Python/pandas

- McKinney: *Python for Data Analysis*.
- VanderPlas: *Python Data Science Handbook*.
- Molin: *Hands-On Data Analysis with Pandas*.

Processo analítico e produto de dados

- CRISP-DM: processo padrão para projetos de mineração de dados.
- IBM: *Foundational Methodology for Data Science*.
- Provost e Fawcett: *Data Science for Business*.

Estatística e análise exploratória

- Bussab e Morettin: *Estatística Básica*.
- Morettin e Singer: *Estatística e Ciência de Dados*.
- Wickham: *Tidy Data*.

Visualização e comunicação

- Knaflic: *Storytelling with Data*.
- Wilke: *Fundamentals of Data Visualization*.
- Healy: *Data Visualization: A Practical Introduction*.

Mensagem final

O que será valorizado na disciplina?

- Clareza na formulação do problema.
- Capacidade de transformar dados brutos em base analítica confiável.
- Análises simples, bem executadas e interpretáveis.
- Visualizações que comuniquem evidências, não apenas gráficos bonitos.
- Recomendações úteis, factíveis e coerentes com os dados.
- Código organizado, reprodutível e documentado.

Atividade diagnóstica

Atividade prática: Raio-X de uma base de dados

Objetivo da atividade

Verificar a fluência inicial da turma com ambiente Python, leitura de dados, manipulação com `pandas`, construção de indicadores, visualização simples e interpretação de resultados.

Base de dados

A atividade utilizará a base fictícia `vendas_diagnostico.csv`, contendo registros simulados de vendas por data, região, produto, canal, quantidade, preço unitário e faturamento.

- A atividade é diagnóstica: o foco é identificar o ponto de partida da turma.
- Pode ser feita em dupla, mas cada estudante deve compreender o código produzido.
- A entrega será um notebook ou script com código, resultados e breve interpretação.

O que será observado?

Dimensão	Evidência esperada
Ambiente	Consegue abrir notebook, VS Code, Jupyter ou Colab e executar células.
Bibliotecas	Consegue importar `pandas`, `matplotlib` e bibliotecas básicas.
Leitura de dados	Consegue ler um arquivo `csv` e inspecionar sua estrutura.
Manipulação	Usa operações como seleção de colunas, filtros, agrupamentos e ordenamento.
Datas	Consegue converter uma coluna de data e agregar informações por mês.
Visualização	Produz gráficos simples e minimamente legíveis.
Interpretação	Consegue transformar resultados em achados claros e perguntas adicionais.

Roteiro da atividade

1. **Configuração do ambiente**: abrir notebook ou script e importar bibliotecas.
2. **Leitura da base**: carregar o arquivo `vendas_diagnostico.csv`.
3. **Inspeção inicial**: verificar linhas, colunas, tipos, ausentes e estatísticas básicas.
4. **Indicadores**: calcular faturamento total, ticket médio, produto mais vendido e faturamento por região.
5. **Análise temporal**: calcular faturamento mensal.
6. **Visualização**: produzir pelo menos dois gráficos.
7. **Interpretação**: escrever os principais achados e uma pergunta adicional.

Tarefas: leitura e inspeção dos dados

Parte 1 – Ambiente e leitura

1. Importar as bibliotecas necessárias.
2. Mostrar a versão do Python.
3. Mostrar a versão do `pandas`.
4. Ler a base `vendas_diagnostico.csv` disposta em <https://github.com/ufpbcdn/analise-dados>

Parte 2 – Inspeção inicial

1. Mostrar as cinco primeiras linhas.
2. Informar o número de linhas e colunas.
3. Listar os nomes das colunas.
4. Verificar os tipos das variáveis.

Tarefas: indicadores e visualização

Parte 3 – Indicadores

1. Calcular o faturamento total.
2. Calcular o ticket médio.
3. Identificar o produto mais vendido em quantidade.
4. Identificar a região com maior faturamento.
5. Calcular o faturamento por mês.

Parte 4 – Visualizações

1. Construir um gráfico de barras com o faturamento por região.
2. Construir um gráfico de linha com o faturamento mensal.
3. Inserir título, rótulos dos eixos e formatação mínima.

Tarefas: interpretação dos resultados

Parte 5 – Interpretação

Ao final do notebook, escreva uma breve interpretação respondendo:

1. Qual região apresentou maior faturamento?
2. Qual produto teve maior volume de vendas?
3. O faturamento mensal apresenta crescimento, queda ou oscilação?
4. Existe algum problema de qualidade nos dados?
5. Que pergunta adicional você faria para aprofundar a análise?

Formato sugerido da conclusão

Encontramos que _____ apresenta maior _____ em comparação com _____. Isso sugere que _____. Para aprofundar, precisaríamos analisar _____.