Introdução à Análise de Dados e a Linguagem Python

Análise de Dados

Aléssio Tony Cavalcanti de Almeida

Centro de Ciências Sociais Aplicadas
Universidade Federal da Paraíba
alessio@lema.ufpb.br

CIÊNCIA DE
DADOS PARA
NEGÓCIOS

João Pessoa, 2026

Plano de Aula

Objetivo: compreender como problemas organizacionais podem ser traduzidos em perguntas analíticas e iniciar a construção de um fluxo reprodutível de análise de dados com Python.

Ao final da aula, o estudante deverá ser capaz de:

<+>distinguir problema de negócio, pergunta analítica e indicador;reconhecer as etapas de um projeto de análise de dados;relacionar as fases do CRISP-DM a tarefas práticas em Python;executar uma primeira leitura, inspeção e descrição de uma base de dados com pandas.

Estrutura da Aula

1. Introdução à Análise de Dados e Contexto de Negócios
2. O que é Análise de Dados?
3. Metodologias e Processos de Análise de Dados: CRISP-DM
4. Divisões da Análise de Dados
5. Ética e LGPD na Análise de Dados
6. Introdução à Linguagem Python para Análise de Dados
   - Preparação do ambiente
   - Python e o Ecossistema de Data Science
   - Conceitos Gerais da Linguagem Python
     - Exercícios
7. Atividade

Introdução à Análise de Dados e Contexto de Negócios

Introdução

As organizações bem-sucedidas tomam decisões baseadas em evidências para encontrar...

1. novas oportunidades
2. identificar pontos fracos
3. aumentar a eficiência
4. aprimorar a satisfação do cliente

O Valor da Análise de Dados para às Organizações

Análise de dados não é apenas sobre números, mas sobre **transformar dados em insights** acionáveis que impulsionam o valor de negócio:

- Tomada de Decisão Orientada por Dados: Menos intuição, mais evidência.
- Otimização de Processos: Identificação de gargalos e ineficiências.
- Personalização da Experiência do Cliente: Marketing direcionado e melhor serviço.
- Inovação e Desenvolvimento de Novos Produtos: Descoberta de necessidades não atendidas.
- Mitigação de Riscos: Identificação de fraudes e padrões de falha.

O que é Análise de Dados?

O que é Análise de Dados?

Definição na área de negócios

Processo de examinar dados brutos para revelar **tendências** e **descobrir** informações úteis para responder perguntas relacionadas ao desempenho organizacional.

A análise de dados está preocupada com a **obtenção de dados**, **identificação de informações** significativas e **inferências** resultantes.

Exemplos: Como a Análise de Dados pode ser Utilizada para ...?

- **Setor Financeiro**: Análise de transações para detectar fraudes, prever inadimplência e otimizar investimentos.
- **Varejo**: Análise de comportamento de compra para personalizar ofertas, otimizar estoques e melhorar a experiência do cliente.
- **Saúde**: Análise de registros médicos para prever surtos de doenças, otimizar tratamentos e melhorar a gestão hospitalar.
- **Marketing**: Análise de campanhas publicitárias para medir eficácia, segmentar audiências e otimizar gastos com mídia.
- **Logística**: Análise de rotas de entrega para otimizar custos, melhorar prazos e reduzir emissões de carbono.
- **Educação**: Análise de desempenho de alunos para personalizar o aprendizado, identificar áreas de melhoria e prever evasão escolar.

Exemplo: Hotéis e Resorts

Usar dados de visitas anteriores de clientes

Analisar os gastos de clientes e procurar correlações com outros fatores:

- Condições climáticas
- Eventos locais/regionais
- Incentivos promocionais de alimentação e bebida
- Preços
- Características do cliente (idade, família, tempo de permanência)

Objetivo

Identificar padrões de comportamento dos clientes para melhorar a experiência e aumentar a receita.

Exemplo: Análise de Dados na UFPB

- Há uma abundância de dados na UFPB, incluindo registros cadastrais, acadêmicos e administrativos. Ademais, existem dados de pesquisas acadêmicas, como publicações, softwares, citações e colaborações.
- Esses dados podem ser utilizados para melhorar a gestão acadêmica, identificar tendências de desempenho dos alunos e servidores, otimizar recursos e apoiar decisões estratégicas.

Desafios da Análise de Dados na UFPB

1. Dados dispersos em diferentes sistemas e formatos.
2. Questões de privacidade e segurança dos dados.
3. Necessidade de habilidades especializadas em análise de dados.
4. Falta de integração entre os sistemas existentes.

Metodologias e Processos de Análise de Dados: CRISP-DM

Metodologias: O que é CRISP-DM?

CRISP-DM (Cross-Industry Standard Process for Data Mining) é uma metodologia amplamente adotada que descreve as fases comuns de um projeto de mineração de dados.

- Oferece uma estrutura organizada e iterativa.
- Flexível para diferentes tipos de projetos de dados.
- Promove a colaboração entre especialistas de negócio e técnicos.

As Seis Fases do CRISP-DM

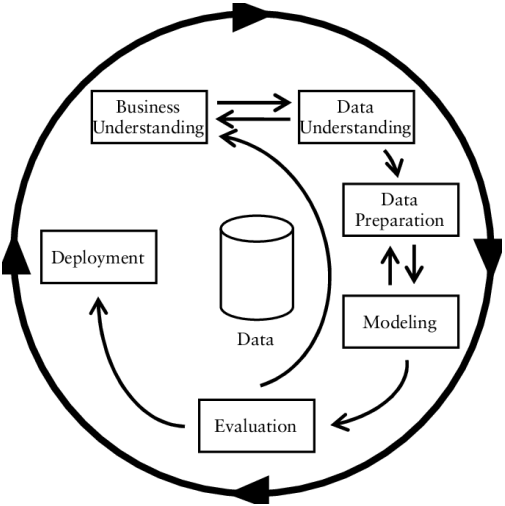

CRISP-DM como roteiro prático da disciplina

Fase	Entregável típico em uma análise de dados
Entendimento do negócio	Pergunta analítica, público-alvo, decisão a apoiar
Entendimento dos dados	Dicionário de dados, tipos de variáveis, qualidade da base
Preparação dos dados	Base tratada, variáveis derivadas, filtros e agregações
Modelagem	Indicadores, segmentações, regressões ou modelos preditivos
Avaliação	Validação técnica e interpretação substantiva dos resultados
Implantação	Relatório, dashboard, apresentação ou recomendação executiva

Fase 1: Entendimento do Negócio

Onde tudo começa:

- Definição clara dos objetivos de negócio (ex: reduzir churn, aumentar vendas).
- Avaliação da situação atual (recursos, restrições, riscos).
- Determinação dos objetivos de mineração de dados (o que os dados precisam nos dizer).
- Planejamento inicial do projeto.

Fase 2: Entendimento dos Dados

Explorando o universo de dados disponível:

- Coleta inicial dos dados.
- Descrição dos dados (tipos, formatos, fontes).
- Exploração dos dados para identificar padrões iniciais e anomalias.
- Verificação da qualidade dos dados (dados ausentes, inconsistências).

Fase 3: Preparação dos Dados

Transformando dados brutos em um formato útil para a análise.

- Pode envolver a escrita de código para capturar, filtrar, limpar, combinar e agregar dados de várias fontes.
- Seleção de dados relevantes.
- Limpeza de dados (tratamento de valores ausentes, correção de erros).
- Construção de novos atributos (engenharia de features).
- Integração de dados de múltiplas fontes.
- Formatação e transformação dos dados.

Pipeline de dados e Ingestão de Dados

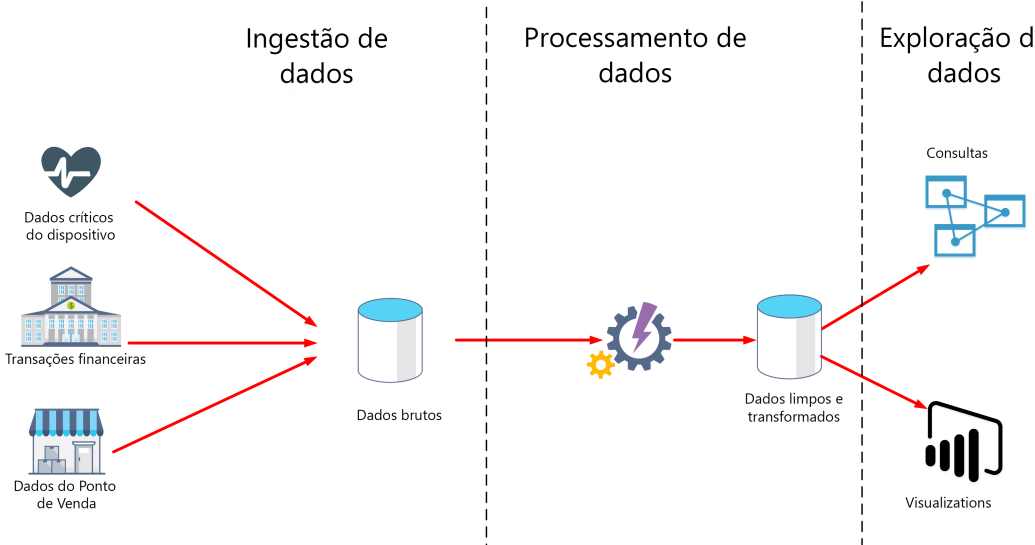

Pipeline de Dados e Ingestão de Dados

O que é ingestão de dados?

processo de obtenção e importação de dados para uso imediato ou armazenamento em um banco de dados. A finalidade do processo de ingestão é **capturar** dados e **armazená-los**.

- Esses dados brutos podem ser mantidos em um repositório, como um SGBD ou em um conjunto de arquivos.
- Também é possível executar algumas transformações nesta fase, convertendo dados em um formato padrão para processamento posterior.

ETL (Extração, Transformação e Carga)

O que é ETL?

Significa extração, transformação e carga de dados. Os dados brutos são coletados e transformados antes de serem salvos.
As etapas de extração, transformação e carregamento podem ser executadas como um pipeline contínuo de operações.

A fase de processamento de dados ocorre depois que os dados são coletados e ingeridos.

- A transformação de dados pode incluir limpeza, normalização, agregação e outras operações para preparar os dados para análise.
- A carga envolve a inserção dos dados transformados em um sistema de armazenamento, como um banco de dados ou data warehouse.

Processamento e a ingestão de dados: ETL

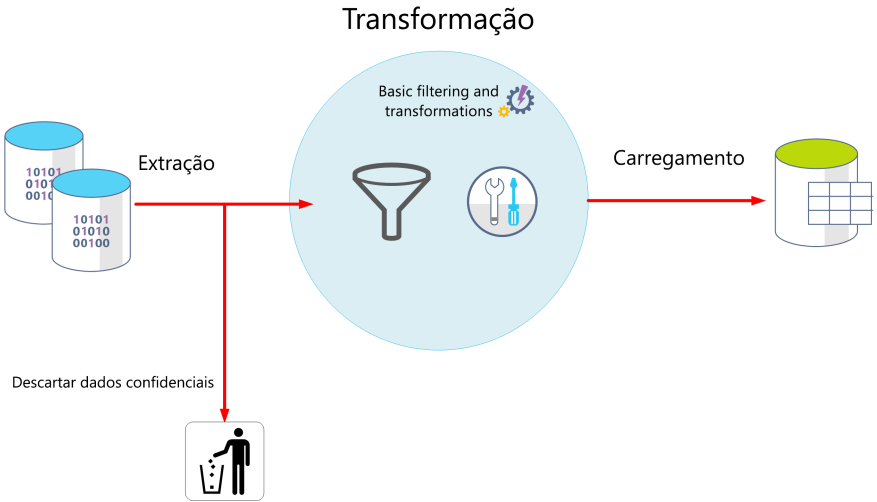

Fase 4: Modelagem

Aplicação de técnicas de análise para construir modelos:

- Seleção de técnicas de modelagem (regressão, classificação, agrupamento, etc.).
- Geração de testes e cenários.
- Construção do modelo (treinamento do algoritmo).
- Avaliação preliminar do modelo (métricas internas).

Fase 5: Avaliação

Avaliando a qualidade e a utilidade do modelo:

- Avaliação dos resultados do modelo em relação aos objetivos de negócio.
- Revisão do processo para identificar pontos fracos.
- Determinação dos próximos passos (deploy, refino).
- Decisão de usar ou não o modelo.

Fase 6: Implantação (Deployment)

Colocando o modelo em uso prático:

- Planejamento da implantação (como o modelo será integrado ao sistema).
- Monitoramento do modelo (desempenho, degradação).
- Geração de relatório final e apresentação dos resultados.
- Manutenção e acompanhamento contínuos.

Divisões da Análise de Dados

Divisões da análise de dados

Modelo de ascedência analítica de Gartner

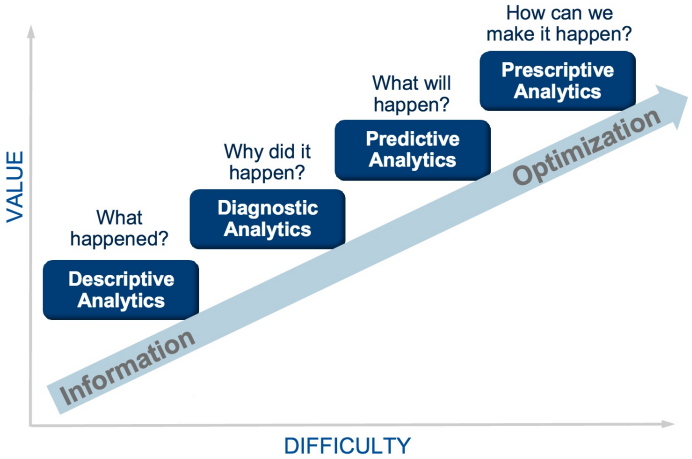

Divisões da análise de dados

- **Descritiva**: o que aconteceu? Ex: análise de vendas passadas, relatórios financeiros.
- **Diagnóstica**: por que aconteceu? Ex: análise de causas de queda nas vendas, identificação de problemas operacionais.
- **Preditiva**: o que vai acontecer? Ex: previsão de vendas futuras, análise de tendências de mercado.
- **Prescritiva**: o que deve ser feito? Ex: recomendações de ações para otimizar vendas, sugestões de estratégias de marketing.
- **Cognitiva**: como automatizar as decisões? Ex: chatbots, assistentes virtuais que aprendem com interações.

Ética e LGPD na Análise de Dados

Ética na Análise de Dados

Considerações cruciais para um uso responsável dos dados:

- **Viés e Discriminação**: Algoritmos podem perpetuar ou amplificar vieses presentes nos dados.
- **Privacidade e Confidencialidade**: Proteção de informações pessoais e sensíveis.
- **Transparência e Explicabilidade**: Entender como as decisões dos modelos são tomadas.
- **Responsabilidade**: Quem é responsável pelas consequências das análises e modelos?
- **Segurança dos Dados**: Proteção contra acessos não autorizados e vazamentos.

Introdução à LGPD (Lei Geral de Proteção de Dados)

Lei nº 13.709/2018: Quadro legal para o tratamento de dados pessoais no Brasil.

- **Objetivo Principal**: Proteger os direitos fundamentais de liberdade e de privacidade e o livre desenvolvimento da personalidade da pessoa natural.
- **Abrangência**: Aplica-se a qualquer operação de tratamento de dados pessoais realizada por pessoa natural ou jurídica de direito público ou privado, independentemente do meio, do país de sua sede ou do país onde estejam localizados os dados, desde que:
  - A operação de tratamento seja realizada no Brasil.
  - O objetivo do tratamento seja a oferta ou o fornecimento de bens ou serviços a indivíduos localizados no Brasil.
  - Os dados pessoais tenham sido coletados no Brasil.

Princípios da LGPD

A LGPD estabelece 10 princípios que devem nortear o tratamento de dados pessoais:

1. Finalidade
2. Adequação
3. Necessidade
4. Livre Acesso
5. Qualidade dos Dados
6. Transparência
7. Segurança
8. Prevenção
9. Não Discriminação
10. Responsabilização e Prestação de Contas

Direitos dos Titulares de Dados na LGPD

A LGPD confere aos indivíduos uma série de direitos sobre seus dados pessoais:

- Confirmação da existência de tratamento.
- Acesso aos dados.
- Correção de dados incompletos, inexatos ou desatualizados.
- Anonimização, bloqueio ou eliminação de dados desnecessários ou tratados em desconformidade.
- Portabilidade dos dados.
- Eliminação dos dados pessoais tratados com consentimento.
- Informação sobre compartilhamento.
- Revogação do consentimento.

Introdução à Linguagem Python para Análise de Dados

Por que Python para Análise de Dados?

Python será utilizado como ambiente operacional da disciplina porque permite construir um fluxo completo de análise:

- leitura de dados em múltiplos formatos;
- limpeza, transformação e integração de bases;
- análise exploratória e construção de indicadores;
- visualização de evidências;
- modelagem estatística e preditiva;
- documentação reprodutível em notebooks.

Ideia central

Não basta saber programar: é preciso estruturar um problema, preparar os dados e comunicar evidências úteis para decisão.

As linguagens mais populares (Stack Overflow, 2024)

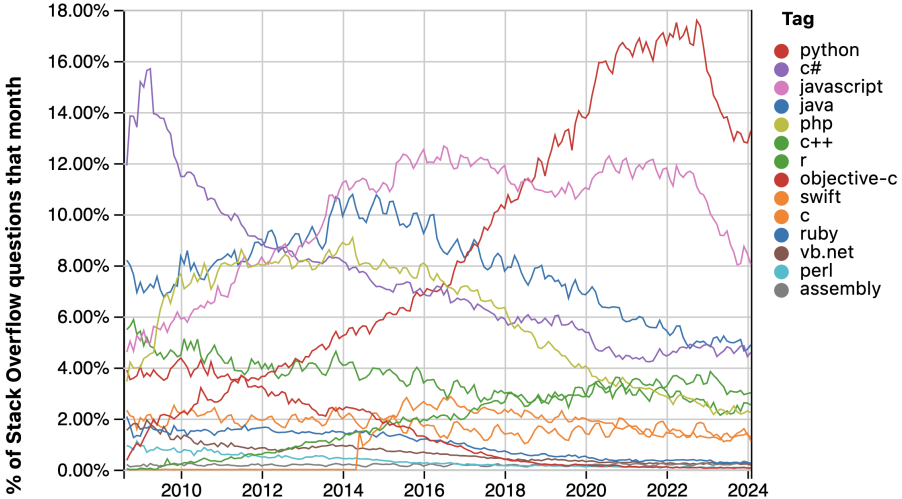

As linguagens mais populares: Python x R (Stack Overflow, 2024)

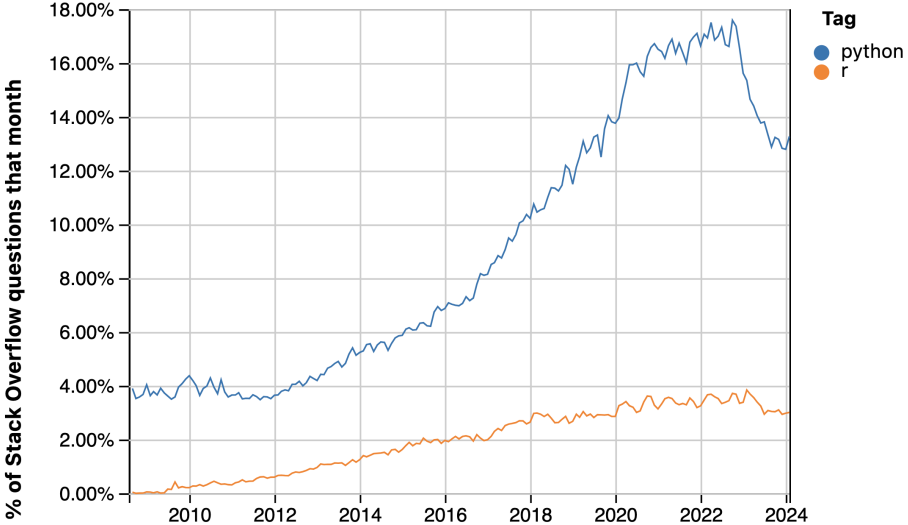

Análise de Dados (Stack Overflow, 2019)

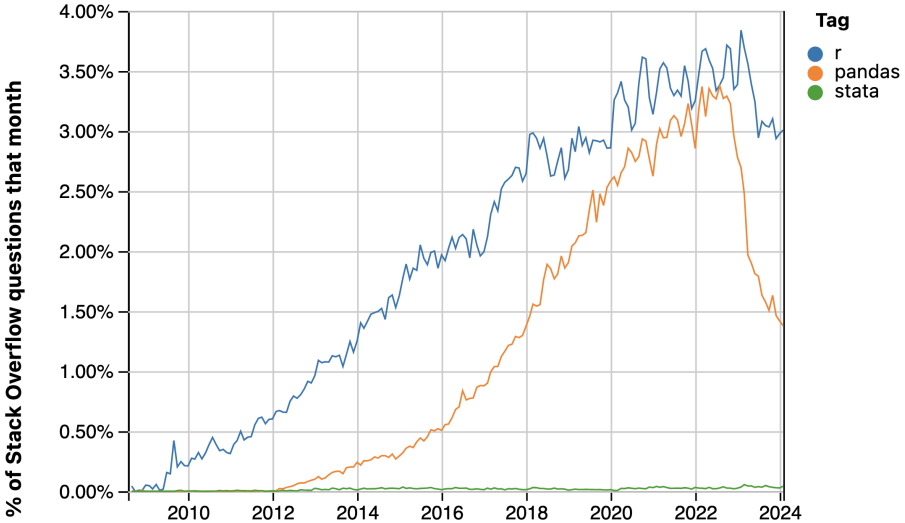

Antes do código: como olhar para uma base de dados?

Antes de aplicar comandos em Python, é preciso identificar:

<+>**Unidade de análise**: cliente, aluno, município, produto, transação?**Variáveis**: o que cada coluna representa?**Observações**: o que cada linha representa?**Chaves**: existe identificador único?**Qualidade**: há valores ausentes, duplicados ou inconsistentes?**Granularidade**: os dados estão no nível adequado para responder à pergunta?

Instalação do Python

Download e instalação

- Acesse o site oficial do Python (https://www.python.org/downloads/):
- Escolha a versão compatível com seu sistema operacional (Windows, macOS ou Linux).
- Baixe o instalador adequado.
- Marque a opção para adicionar o Python ao seu PATH (importante para executar comandos Python em qualquer lugar do terminal).

Abra o terminal (Prompt de Comando no Windows).

```
# Digite o comando para checar a instalacao
python3 --version
```

Instalação do editor de código ou IDE

- Editor de código: uma opção leve e simples. **Exemplos**: Sublime Text, Visual Studio Code, Notepad++, BBEdit, etc.
- Ambiente de Desenvolvimento Integrado (IDE): Oferece mais recursos e funcionalidades. **Exemplos**: PyCharm, Spyder, Visual Studio Code com extensões Python.

Recomendações

- Visual Studio Code (Extensões: Python, Live Share, Data Wrangler, TODOs)
- Google Colab (ambiente online para testes e explorações iniciais)

Preparação do ambiente: Nuvem

O Colab, ou "Colaboratory", é uma ferramenta do Google que permite escrever e executar Python no navegador

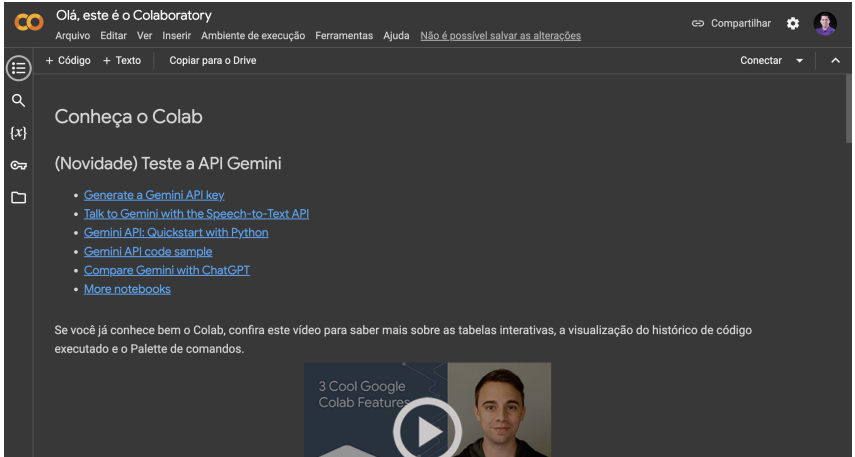

Preparação do ambiente

Ambiente Local

- Python 3

  <https://www.python.org>
- VS Code

  <https://code.visualstudio.com>
- PIP

  <https://pip.pypa.io>
- Jupyter

  <https://jupyter.org>

Instalando bibliotecas e pacotes

Comando pip

Utilize o comando `pip install` para instalar bibliotecas e pacotes Python diretamente do terminal.

Ex: `pip install numpy pandas matplotlib`

Python e Data Science

A utilidade do Python para a ciência de dados advém principalmente do grande e ativo ecossistema de pacotes:

1. **NumPy**: para manipulação de matrizes homogêneas de dados. A base para computação numérica de alta performance.
2. **Pandas**: para manipulação de dados heterogêneos e rotulados, como DataFrames e Series. Ideal para dados tabulares e séries temporais.
3. **SciPy**: para tarefas comuns de computação científica, como otimização, integração e transformada de Fourier.
4. **Matplotlib**: para visualizações de qualidade de publicação. Permite criar diversos tipos de gráficos.
5. **IPython**: para execução interativa e compartilhamento de código, incluindo o Jupyter Notebook.
6. **Scikit-Learn**: para machine learning, oferecendo algoritmos de classificação, regressão, clustering, etc.

Conceitos gerais

Como qualquer linguagem de programação, o Python é formado por:

1. comandos
2. tipos de dados
3. variáveis
4. expressões
5. estruturas de dados
6. funções
7. bibliotecas

Exercício 1: Lógica Básica

Vamos começar a pensar como um(a) programador(a)?

- Fazer um código para checar se um número digitado é positivo, negativo ou zero.

Exercício 2: Lógica Básica

- Fazer um código para checar se um número digitado é par ou ímpar.

Exercício 3: Cálculo Simples

- Faça um programa que pergunte o quanto você ganha por hora e o total de horas trabalhadas por mês. Calcule e mostre o total do seu salário no mês.

Exercício 4: Loja de Tintas - Parte 1

- Faça um programa para loja de tintas. O programa deverá pedir o tamanho em metros quadrados da área a ser pintada. Considere que a cobertura da tinta é de 1 litro para cada 3 metros quadrados e que a tinta é vendida em latas de 18 litros, que custam R$ 80,00 cada. Informe ao usuário a quantidade de latas de tinta a serem compradas e o preço total.

Exercício 5: Loja de Tintas - Parte 2

- Faça outro programa para loja de tintas. O programa deverá pedir o tamanho em metros quadrados da área a ser pintada. Considere que a cobertura da tinta é de 1 litro para cada 6 metros quadrados e que a tinta é vendida em latas de 18 litros, que custam R$ 80,00 ou em galões de 4 litros, que custam R$ 25,00. Informe ao usuário as quantidades de tinta a serem compradas e os respectivos preços em 3 situações:
  1. comprar apenas latas de 18 litros;
  2. comprar apenas galões de 4 litros;
  3. misturar latas e galões.

Exercício 6: Matemática Financeira

- Faça um programa de matemática financeira, para simular o valor de uma prestação do veículo, com as seguintes entradas: 1) valor do produto; 2) Entrada; 3) Número de prestações a.m. para pagamento do saldo; 4) taxa de juros a.m.
  Para sua realização, assuma um regime de juros composto.

Exercício 7: Análise de Dados Básica com Pandas

- Suponha que você tenha os seguintes dados em um arquivo ‘vendas.csv‘:
  Produto,Preco,Quantidade,Data
  A,10.0,5,2024-01-15
  B,25.5,2,2024-01-15
  A,10.0,3,2024-01-16
  C,12.0,1,2024-01-16
  1. Carregue esses dados em um DataFrame Pandas.
  2. Mostre as primeiras 2 linhas do DataFrame.
  3. Calcule o valor total de vendas para cada produto (Preco * Quantidade). Adicione essa informação como uma nova coluna ’Total_Vendas’.
  4. Qual o produto com o maior ’Total_Vendas’?

Exercício 8: Visualização Básica com Matplotlib

- Usando o DataFrame do Exercício 7:
  1. Gere um gráfico de barras mostrando o 'Total_Vendas' para cada 'Produto'.
  2. Opcional: Adicione um título ao gráfico e rótulos aos eixos.

Exercício 9: Análise de Dados com Pandas

- Suponha que você tenha os seguintes dados em um arquivo ‘clientes.csv‘:

```
Cliente,Idade,Genero,Compras\\
Ana,28,Feminino,150.0\\
Bruno,35,Masculino,200.0\\
Carlos,22,Masculino,100.0\\
Diana,30,Feminino,250.0\\
```

1. Carregue esses dados em um DataFrame Pandas.
2. Mostre as primeiras 3 linhas do DataFrame.
3. Calcule a média de compras por gênero.
4. Crie uma nova coluna ’Idade_Ajustada’ que seja a idade do cliente menos 5 anos.
5. Qual o gênero com a maior média de compras?

Atividade

Atividade prática: Mini-sprint CRISP-DM em Python

Situação-problema

Uma empresa varejista multicanal observou queda recente na margem de lucro e aumento das reclamações de clientes. A diretoria não sabe se o problema está associado a uma região, canal de venda, categoria de produto ou combinação desses fatores.

Você recebeu a base vendas_diagnostico_2.csv (repositório de dados da disciplina GitHub) e deve produzir um diagnóstico inicial.

Questões norteadoras

1. Sua tarefa é identificar:
2. quais problemas de qualidade existem na base;
3. quais segmentos apresentam pior desempenho;
4. quais indicadores sustentam essa conclusão;
5. que recomendação preliminar poderia ser feita à diretoria.

Roteiro da atividade

1. **Entendimento do negócio**: escreva uma pergunta analítica e uma decisão que a análise pode apoiar.
2. **Entendimento dos dados**: identifique unidade de análise, variáveis, tipos de dados e possíveis problemas.
3. **Preparação**: trate duplicidades, datas, categorias inconsistentes e valores ausentes.
4. **Indicadores**: calcule receita, custo, margem, taxa de desconto, satisfação média e percentual de entregas no prazo.
5. **Exploração**: compare os indicadores por região, canal e categoria de produto.
6. **Conclusão**: produza três achados e uma recomendação executiva.

Referências I