

Análise Exploratória de Dados e Estatísticas Descritivas com Pandas

Análise de Dados

Aléssio Tony Cavalcanti de Almeida

Centro de Ciências Sociais Aplicadas
Universidade Federal da Paraíba
alessio@lema.ufpb.br



CIÊNCIA DE
DADOS PARA
NEGÓCIOS

Plano de aula

Elemento	Definição operacional
Problema central	Estimar e interpretar indicadores educacionais por município sem produzir médias enviesadas.
Ferramenta	pandas: describe, groupby, agg, transform, pivot_table, funções próprias.
Produto da aula	Uma tabela municipal com média simples, média ponderada pela matrícula, diferença entre métodos e flags de outliers.
Forma de trabalho	PRIMM: prever, executar, investigar, modificar e produzir.
Critério de sucesso	O aluno explica quando usar média simples, quando usar média ponderada e como documentar outliers.

Objetivos operacionais

Ao final da aula, o aluno deve ser capaz de:

- 1 inspecionar uma base com `info()`, `describe()`, `value_counts()` e métricas de qualidade;
- 2 produzir estatísticas descritivas por grupos com `groupby()` e `agg()`;
- 3 calcular média ponderada e justificar o peso usado;
- 4 comparar média simples versus média ponderada em indicadores de escola;
- 5 identificar outliers por boxplot/IQR e regra dos dois desvios-padrão;
- 6 decidir se um valor atípico deve ser corrigido, preservado, transformado ou analisado separadamente.

Mapa da aula

- ① **Abertura:** o ranking municipal que muda quando usamos matrícula como peso.
- ② **Inspeção:** unidade de observação, qualidade, ausentes e distribuição.
- ③ **Descritivas:** medidas de posição, dispersão e quantis.
- ④ **Agrupamentos:** escola $\rightarrow$ município, rede, porte e UF.
- ⑤ **Média ponderada:** o problema da escola pequena ter o mesmo peso da escola grande.
- ⑥ **Outliers:** IQR/boxplot e regra dos dois desvios.
- ⑦ **Entrega:** mini-relatório com evidências e decisão analítica.

Problema motivador

Problema motivador: duas médias para o mesmo município

Município A

Escola	Matrículas	IDEB
A1	50	8,0
A2	900	4,8
A3	850	5,0

Município B

Escola	Matrículas	IDEB
B1	400	5,6
B2	450	5,5
B3	420	5,7

Qual município parece ter melhor desempenho no IDEB?

Aquecimento PRIMM: preveja antes de executar

```
import pandas as pd
import numpy as np

exemplo = pd.DataFrame({
    "municipio": ["A", "A", "A", "B", "B", "B"],
    "matriculas": [50, 900, 850, 400, 450, 420],
    "ideb": [8.0, 4.8, 5.0, 5.6, 5.5, 5.7]
})

saida = exemplo.groupby("municipio").apply(lambda g: pd.Series({
    "media_simples": g["ideb"].mean(),
    "media_ponderada": np.average(g["ideb"], weights=g["matriculas"])
}))
```

Antes de rodar: qual município vence em cada método e por quê.

Discussão: qual média responde à pergunta correta?

Pergunta analítica	Unidade com mesmo peso	Estatística adequada
Qual é o desempenho médio das escolas?	Escola	Média simples das escolas.
Qual é o desempenho médio dos alunos matriculados?	Aluno	Média ponderada pela matrícula.
Qual município tem maior desigualdade entre escolas?	Escola	Desvio-padrão, IQR ou amplitude por escola.
Qual rede concentra escolas críticas?	Escola ou matrícula	Contagem de escolas ou proporção ponderada de matrículas.

Regra prática

A escolha do denominador define a interpretação. Média simples responde a uma pergunta sobre escolas; média ponderada pela matrícula responde a uma pergunta sobre alunos.

Base de trabalho e inspeção inicial

Base de trabalho da aula

Dataset sintético, mas com lógica realista

A aula usa uma base simulada de escolas para permitir execução imediata no notebook. A estrutura replica problemas comuns em bases educacionais: diferenças de porte, redes, ausentes, duplicidades e valores atípicos.

Coluna	Significado
id_escola	Identificador da escola.
id_municipio, municipio, uf	Localização.
rede	Municipal, estadual ou privada.
matriculas	Número de alunos matriculados.
ideb	Indicador educacional de desempenho.
tx_aprovacao	Taxa de aprovação.
nivel_socioeconomico	Índice sintético de contexto.

Criando a base no notebook

```
rng = np.random.default_rng(42)
municipios = pd.DataFrame({
    "id_municipio": [2507507, 2510808, 2504009, 3550308, 3304557,
                     2304400],
    "municipio": ["Joao Pessoa", "Patos", "Campina Grande",
                  "Sao Paulo", "Rio de Janeiro", "Fortaleza"],
    "uf": ["PB", "PB", "PB", "SP", "RJ", "CE"],
    "regiao": ["Nordeste", "Nordeste", "Nordeste", "Sudeste", "Sudeste",
               "Nordeste"]
})

# Gerar escolas com tamanhos diferentes
# O notebook completo contem a funcao de geracao e os casos atipicos.
```

Execute o notebook e confira se cada linha representa uma escola. Depois, responda: a unidade de análise é escola, município ou aluno?

Checklist inicial de qualidade

```
df.info()

df.isna().mean().sort_values(ascending=False)

df.duplicated(["id_escola"]).sum()

df[["ideb", "matriculas", "tx_aprovacao"]].describe()
```

Interpretação esperada

- info() mostra tipos, não apenas nomes de colunas.
- isna().mean() transforma ausentes em proporção.
- duplicated() deve sempre explicitar a chave.
- describe() deve ser lido com atenção a mediana, quartis, mínimo e máximo.

Pergunta diagnóstica: o que é uma linha?

Base no nível de escola

Cada linha contém uma escola em um ano. A matrícula é uma variável da escola.

Erro comum

Agrupar por município e tirar a média do IDEB sem explicitar se o peso é escola ou matrícula.

Se uma escola pequena tem IDEB 8,0 e uma escola grande tem IDEB 4,8, as duas devem ter o mesmo peso em um indicador municipal? Depende de quê?

Estatísticas descritivas

Estatística descritiva: não é só preencher tabela

Família	Métricas	Pergunta que responde
Posição	média, mediana, quartis	Onde está o centro da distribuição?
Dispersão	desvio-padrão, IQR, amplitude	Quão heterogêneas são as escolas?
Forma	assimetria, caudas, histograma	Há concentração, cauda longa ou extremos?
Cobertura	ausentes, duplicidades, n válido	A base sustenta a comparação?
Grupo	média por rede, UF, município	Onde estão as diferenças relevantes?

Ideia-chave

Toda estatística descritiva deve ser ligada a uma decisão: comparar, priorizar, investigar ou comunicar.

Resumo geral com pandas

```
variaveis = ["ideb", "matriculas", "tx_aprovacao", "
              nivel_socioeconomico"]

resumo = (
    df[variaveis]
    .describe(percentiles=[0.10, 0.25, 0.50, 0.75, 0.90])
    .T
    .round(2)
)

resumo
```

Marque uma variável com maior assimetria provável e justifique usando média, mediana e quartis.

Resumo por grupo: rede de ensino

```
resumo_rede = (  
    df.groupby("rede")  
        .agg(  
            n_escolas=("id_escola", "nunique"),  
            matriculas_total=("matriculas", "sum"),  
            ideb_medio=("ideb", "mean"),  
            ideb_mediano=("ideb", "median"),  
            ideb_dp=("ideb", "std"),  
            ideb_q25=("ideb", lambda s: s.quantile(0.25)),  
            ideb_q75=("ideb", lambda s: s.quantile(0.75))  
        )  
        .assign(ideb_iqr=lambda x: x["ideb_q75"] - x["ideb_q25"])  
        .round(2)  
)
```

Qual rede parece mais heterogênea? Que métrica sustenta sua resposta?

Atividade 1: leitura crítica de descritivas

Tempo: 10 minutos.

Tarefa: Escolha uma variável quantitativa e responde: centro, dispersão, cauda e possível problema de qualidade.

Item	O que entregar
Centro	Média e mediana com interpretação.
Dispersão	Desvio-padrão ou IQR.
Alerta	Uma suspeita de outlier, assimetria ou valor inconsistente.
Decisão	O que investigar antes de modelar ou comunicar.

Agrupamentos e médias ponderadas

Agrupar não é neutro

Operação computacional

`groupby()` divide a base em grupos, aplica uma função e combina o resultado.

Operação analítica

Ao agrupar, você muda a unidade de análise. Uma tabela de escolas vira uma tabela de municípios, redes ou UFs. A interpretação muda junto.

Pergunta que deve vir antes do código

Estou resumindo escolas, alunos, municípios ou redes? O peso de cada linha deve ser igual ou proporcional a alguma variável?

Média simples por município

```
municipal_simples = (  
    df.groupby(["id_municipio", "municipio", "uf"])  
        .agg(  
            n_escolas=("id_escola", "nunique"),  
            matriculas_total=("matriculas", "sum"),  
            ideb_media_simples=("ideb", "mean")  
        )  
        .reset_index()  
)
```

Interpretação correta

Cada escola entra com o mesmo peso. O resultado descreve o IDEB médio das escolas do município.

Média ponderada pela matrícula

```
def media_ponderada(valor, peso):  
    base = pd.DataFrame({"valor": valor, "peso": peso}).dropna()  
    if base.empty or base["peso"].sum() == 0:  
        return np.nan  
    return np.average(base["valor"], weights=base["peso"])  
  
municipal_ponderado = (  
    df.groupby(["id_municipio", "municipio", "uf"])  
        .apply(lambda g: pd.Series({  
            "ideb_media_ponderada": media_ponderada(g["ideb"], g["  
                matriculas"])),  
            "matriculas_com_ideb": g.loc[g["ideb"].notna(), "matriculas"  
                ].sum()  
        })))  
    .reset_index()  
)
```

Comparando os dois métodos

```
comparacao = (  
    municipal_simples  
    .merge(municipal_ponderado, on=["id_municipio", "municipio", "uf"]  
          )  
    .assign(  
        diferenca=lambda x: x["ideb_media_simples"] - x["  
                                ideb_media_ponderada"],  
        abs_diferenca=lambda x: x["diferenca"].abs()  
    )  
    .sort_values("abs_diferenca", ascending=False)  
)  
  
comparacao[["municipio", "uf", "n_escolas", "matriculas_total",  
            "ideb_media_simples", "ideb_media_ponderada", "diferenca"]  
]
```

Em que municípios a média simples mais se distancia da ponderada? O que isso sugere sobre a relação entre porte da escola e IDEB?

Atividade 2: a média que muda o ranking

Tempo: 15 minutos.

Tarefa: gerar dois rankings municipais, um por média simples e outro por média ponderada pela matrícula.

Etapa	Entrega
1. Ranking simples	Top 5 por ideb_media_simples.
2. Ranking ponderado	Top 5 por ideb_media_ponderada.
3. Diferença	Municípios que mais mudaram de posição.
4. Interpretação	Uma hipótese substantiva para a mudança.

Código de apoio: mudança de ranking

```
rank = comparacao.copy()
rank["rank_simples"] = rank["ideb_media_simples"].rank(ascending=False
    , method="min")
rank["rank_ponderado"] = rank["ideb_media_ponderada"].rank(ascending=
    False, method="min")
rank["mudanca_rank"] = rank["rank_simples"] - rank["rank_ponderado"]

rank.sort_values("mudanca_rank", key=lambda s: s.abs(), ascending=
    False)[[
    "municipio", "rank_simples", "rank_ponderado", "mudanca_rank",
    "ideb_media_simples", "ideb_media_ponderada"
]]
```

Registre uma frase: "O ranking mudou porque..."

Visualização exploratória

Visualização exploratória: olhar antes de concluir

Objetivo	Gráfico recomendado	Pergunta
Distribuição de uma variável	Histograma ou densidade	Há cauda longa, concentração ou lacunas?
Comparar grupos	Boxplot	A dispersão muda por rede ou UF?
Relação entre duas variáveis	Dispersão	Escolas maiores têm IDEB diferente?
Priorizar casos	Barras ordenadas ou tabela	Quais municípios exigem investigação?

Regra prática

O gráfico não substitui a estatística; ele mostra padrões, erros e exceções que a tabela pode esconder.

Histograma e boxplot com pandas/matplotlib

```
import matplotlib.pyplot as plt

ax = df["ideb"].plot(kind="hist", bins=12, title="Distribuicao do IDEB
                                                    das escolas")

ax.set_xlabel("IDEB")
plt.show()

ax = df.boxplot(column="ideb", by="rede")
ax.set_title("IDEB por rede")
ax.set_xlabel("Rede")
ax.set_ylabel("IDEB")
plt.suptitle("")
plt.show()
```

Qual rede tem maior dispersão? O boxplot sugere valores atípicos?

Dispersão: porte da escola versus IDEB

```
ax = df.plot(  
    kind="scatter",  
    x="matriculas",  
    y="ideb",  
    title="Porte da escola e IDEB"  
)  
ax.set_xlabel("Matriculas")  
ax.set_ylabel("IDEB")  
plt.show()
```

Discussão orientada

Se escolas pequenas estão concentradas nos extremos, a média simples pode amplificar casos pouco representativos em termos de matrícula.

Problema
0000

Base
00000

Estatísticas descritivas
00000

Agg
0000000

Visualização
0000

Outliers
●0000000

Desafio integrado
00000

Fechamento
0000

Outliers

O que é um outlier?

Definição operacional

Outlier é uma observação que se distancia do padrão dominante dos dados e, por isso, precisa ser investigada antes de ser usada, removida ou comunicada.

Erro

- digitação
- unidade errada
- duplicidade

Caso legítimo

- escola muito grande
- município petrolífero
- evento raro

Sinal analítico

- desigualdade
- política focalizada
- mudança estrutural

Dois métodos simples para a aula

Método	Regra	Quando usar com cautela
Boxplot/IQR	Outlier se $x < Q_1 - 1,5 \cdot IQR$ ou $x > Q_3 + 1,5 \cdot IQR$	Distribuições muito assimétricas ou com grupos misturados.
Dois desvios	Outlier se $ x - \bar{x} > 2s$	Dados não normais, caudas longas ou média muito influenciada por extremos.

Boa prática

A regra marca candidatos a investigação, não autoriza remoção automática.

Função 1: regra do boxplot/IQR

```
def limites_iqr(s, k=1.5):  
    q1 = s.quantile(0.25)  
    q3 = s.quantile(0.75)  
    iqr = q3 - q1  
    return q1 - k * iqr, q3 + k * iqr  
  
def flag_outlier_iqr(s, k=1.5):  
    inferior, superior = limites_iqr(s.dropna(), k=k)  
    return (s < inferior) | (s > superior)  
  
df["outlier_ideb_iqr"] = flag_outlier_iqr(df["ideb"])
```

Liste as escolas marcadas e classifique: erro provável, caso legítimo ou precisa investigar.

Função 2: regra dos dois desvios-padrão

```
def flag_outlier_2dp(s, k=2):  
    media = s.mean()  
    desvio = s.std()  
    return (s - media).abs() > k * desvio  
  
df["outlier_ideb_2dp"] = flag_outlier_2dp(df["ideb"])  
  
comparar_flags = df.loc[  
    df["outlier_ideb_iqr"] | df["outlier_ideb_2dp"],  
    ["id_escola", "municipio", "rede", "matriculas", "ideb",  
     "outlier_ideb_iqr", "outlier_ideb_2dp"]  
]
```

Os dois métodos marcaram os mesmos casos? Quando a divergência entre métodos é informativa?

Outlier contextual: comparar dentro do município

```
def zscore_grupo(s):  
    return (s - s.mean()) / s.std(ddof=0)  
  
df["z_ideb_municipio"] = (  
    df.groupby("id_municipio")["ideb"]  
    .transform(zscore_grupo)  
)  
  
df["outlier_contextual"] = df["z_ideb_municipio"].abs() > 2
```

Interpretação

Uma escola pode não ser extrema no Brasil, mas ser muito diferente das escolas do próprio município. Isso é um outlier contextual.

Atividade 3: investigação de outliers

Tempo: 15 minutos.

Tarefa: aplicar IQR e dois desvios-padrão ao IDEB e à matrícula. Comparar os casos marcados.

Etapa	Entrega
1. Detectar	Tabela com escola, município, valor e método que marcou.
2. Contextualizar	Verificar rede, matrícula e município.
3. Decidir	Preservar, corrigir, remover ou analisar separadamente.
4. Justificar	Uma frase técnica por caso prioritário.

Como decidir o tratamento de outliers?

Situação	Ação recomendada	Documentação mínima
Erro confirmado	Corrigir se houver fonte confiável; caso contrário, remover.	Regra, fonte e valor original.
Valor legítimo e relevante	Preservar e destacar na análise.	Explicação substantiva.
Valor legítimo, mas muito influente	Rodar análise com e sem o caso; usar mediana/log/modelo robusto.	Sensibilidade dos resultados.
Origem incerta	Não remover automaticamente; sinalizar para validação.	Método de detecção e hipótese.

Desafio integrado

Desafio integrado: diagnóstico municipal de IDEB

Tempo: 20 minutos.

Enunciado: construir uma tabela municipal que permita comparar desempenho educacional sem ignorar o porte das escolas.

- 1 Calcule número de escolas e matrículas por município.
- 2 Calcule IDEB médio simples e IDEB médio ponderado por matrícula.
- 3 Calcule a diferença entre as médias.
- 4 Identifique municípios com maior diferença absoluta.
- 5 Aplique uma regra de outlier ao IDEB médio ponderado municipal.
- 6 Escreva 3 evidências objetivas para orientar uma decisão de gestão.

Esqueleto do desafio

```
def resumo_municipal(g):  
    return pd.Series({  
        "n_escolas": g["id_escola"].nunique(),  
        "matriculas_total": g["matriculas"].sum(),  
        "ideb_simples": g["ideb"].mean(),  
        "ideb_ponderado": media_ponderada(g["ideb"], g["matriculas"]),  
        "ideb_mediano": g["ideb"].median(),  
        "ideb_iqr": g["ideb"].quantile(0.75) - g["ideb"].quantile(0.25)  
    })  
  
mun = (  
    df.groupby(["id_municipio", "municipio", "uf"])  
    .apply(resumo_municipal)  
    .reset_index()  
    .assign(dif_simples_pond=lambda x: x["ideb_simples"] - x["  
        ideb_ponderado"])  
)
```


Mini-entrega final da aula

Produto

Um arquivo notebook ou PDF curto com:

- 1 tabela municipal com média simples, ponderada, diferença e número de escolas;
- 2 um gráfico exploratório: boxplot ou dispersão;
- 3 uma tabela de outliers detectados por IQR e/ou dois desvios-padrão;
- 4 três evidências interpretadas em linguagem de decisão;
- 5 uma decisão metodológica explícita: qual média usar e por quê.

Rubrica rápida de avaliação

Critério	0	1	2	Descrição do nível 2
Código executável				Notebook roda sem erro e gera tabelas/gráficos.
Agrupamento correto				Usa chaves corretas e interpreta a unidade de análise.
Média ponderada				Calcula com pesos válidos e compara com média simples.
Outliers				Aplica ao menos uma regra, lista casos e não remove automaticamente.
Interpretação				Produz 3 evidências conectadas à decisão.

Pontuação sugerida

0 a 10 pontos. A entrega deve priorizar evidência objetiva, não volume de texto.

Fechamento

Checklist: o que o aluno deve saber fazer

- 1 Verificar unidade de observação antes de agrupar.
- 2 Separar pergunta sobre escolas de pergunta sobre alunos.
- 3 Usar `groupby().agg()` para estatísticas por grupos.
- 4 Calcular média ponderada com `np.average()`.
- 5 Comparar ranking por média simples e ponderada.
- 6 Identificar outliers por IQR/boxplot e dois desvios-padrão.
- 7 Documentar decisão sobre outliers antes de remover qualquer caso.

Síntese final

A análise exploratória não serve apenas para descrever dados.

Ela serve para evitar decisões erradas produzidas por agregações, médias e exceções mal interpretadas.

Leituras de apoio

- McKinney, W. *Python for Data Analysis*. Capítulos sobre pandas, estatísticas descritivas, preparação, agrupamento e visualização.
- Morettin, P. A.; Bussab, W. O. *Estatística Básica*. Parte I: análise exploratória, medidas-resumo e boxplots.
- Wickham, H. *Tidy Data*. Estruturação de dados para facilitar manipulação, modelagem e visualização.
- Wilke, C. O. *Fundamentals of Data Visualization*. Distribuições, boxplots, relações e comunicação visual.